

(1)

۱۰۰۰

~~(x~~

Chernoff/Hoeffding's Ineq. 70

$$\Rightarrow P(\hat{A}_2 \gg \hat{A}_1) \approx \exp\left(-\frac{\Delta^r}{r\left(\frac{\delta_1^r}{m_1} + \frac{\delta^r}{m_r}\right)}\right)$$

SADECHI



expect regret in exploration phases $m_1 \Delta$

۱۳

$$P(\hat{\mu}_1 \neq \mu_1) = \exp\left(-\frac{\Delta^2}{2\left(\frac{\delta_1^2}{m_1} + \frac{\delta_2^2}{m_2}\right)}\right)$$

آر $n - m_1 - m_2$ exploitation ، آر m_1 ، آر m_2 regret Δ ،

در m_1 و m_2 روز این صورت regret صفر است

$$\rightarrow R_n \leq m_1 \Delta + (n - m_1 - m_2) \Delta \exp\left(-\frac{\Delta^2}{2\left(\frac{\delta_1^2}{m_1} + \frac{\delta_2^2}{m_2}\right)}\right)$$

آر m_1 ، m_2 خطی کوچک باشد ، از exploration این سه برآورد
 ← با برآورد $m_1 \Delta$ کوچک است ، $\hat{\mu}_1$ ، $\hat{\mu}_2$ ، با ریلین برای تعیین روزی
 که باید به سمت اتصال آنکه آر m_1 Suboptimal را commit کنیم بالا می رود
 در نتیجه commitment regret بزرگ می شود که باعث می شود overall
 performance بدتر

بدتر

آر m_1 ، m_2 خطی بزرگ باشد ، از exploration خطی طولانی می شود
 اتصال commitment استیاء در این commitment به صورت خطی کوچک می شود.
 بالین کان رگت exploration $(m_1 \Delta)$ بسیار بزرگ می شود زیرا arm
 غیر بهینه را مقدار در روزی بزرگ می کنیم به طای این که arm optimal را برای تکرار در دسترس
 exploit

$$f(m_1) = \frac{\delta_1^2}{m_1} + \frac{\delta_2^2}{m - m_1}$$

۱۴

$$f'(m_1) = -\frac{\delta_1^2}{m_1^2} + \frac{\delta_2^2}{(m - m_1)^2} = 0 \Rightarrow f(m_1) = 0$$

$$\Rightarrow \frac{\delta_1^2}{m_1^2} = \frac{\delta_2^2}{m_2^2} \quad (m_1, m_2 \leq m) \Rightarrow \frac{m_1}{m_2} = \frac{\delta_1}{\delta_2}$$

$$\rightarrow m_1 = \frac{\delta_1}{\delta_2} m_2 \rightarrow \frac{\delta_1}{\delta_2} m_2 + m_2 = m \Rightarrow m_2 = \frac{\delta_2}{\delta_1 + \delta_2} m$$

$$m_1 = \frac{\delta_1}{\delta_1 + \delta_2} m$$



SADEGHI

تاریخ

Notebook

Year /

Month /

Date /

$$\frac{\sigma_1^2}{m_1} + \frac{\sigma_2^2}{m_2} = \frac{\sigma_1^2}{m \frac{\sigma_1}{\sigma_1 + \sigma_2}} + \frac{\sigma_2^2}{m \frac{\sigma_2}{\sigma_1 + \sigma_2}} = \frac{\sigma_1(\sigma_1 + \sigma_2) + \sigma_2(\sigma_1 + \sigma_2)}{m} \quad (5)$$

$$= \frac{(\sigma_1 + \sigma_2)^2}{m}$$

$$\rightarrow R_n \leq m_2 \Delta + (n - m) \Delta \exp\left(-\frac{m \Delta^2}{2(\sigma_1 + \sigma_2)^2}\right)$$

Join $\sigma_1, \sigma_2, n, m, n$, $m_2 = \frac{m \sigma_2}{\sigma_1 + \sigma_2}$

$$\rightarrow R_n \leq m \Delta \left(\frac{\sigma_2}{\sigma_1 + \sigma_2}\right) + n \Delta \exp\left(-\frac{m \Delta^2}{2(\sigma_1 + \sigma_2)^2}\right)$$

$$\rightarrow \frac{d}{dm} \left[C m \Delta + n \Delta \exp\left(-\frac{m \Delta^2}{2(\sigma_1 + \sigma_2)^2}\right) \right] = 0$$

$$C \Delta - n \Delta \left(\frac{\Delta^2}{2(\sigma_1 + \sigma_2)^2}\right) \exp\left(-\frac{m \Delta^2}{2(\sigma_1 + \sigma_2)^2}\right) = 0$$

$$\exp\left(\frac{m \Delta^2}{2(\sigma_1 + \sigma_2)^2}\right) = \frac{n \Delta^2}{2C(\sigma_1 + \sigma_2)^2}$$

$$\Rightarrow m = \frac{2(\sigma_1 + \sigma_2)^2}{\Delta^2} \ln\left(\frac{n \Delta^2}{2C(\sigma_1 + \sigma_2)^2}\right)$$

$$\rightarrow m = O\left(\frac{(\sigma_1 + \sigma_2)^2}{\Delta^2} \log n\right)$$

با گذشتن m به regret bound، داریم $O\left(\frac{1}{n}\right)$ می شود

نیز exploration regret، commitment regret $= O(1)$ ←

$$R_n \leq C m \Delta = O\left(\frac{(\sigma_1 + \sigma_2)^2}{\Delta} \log n\right) \quad \text{می شود}$$

① اینرسی نیزه: نیزه که کمای بالاتر ~ این معنی است که $\hat{\mu}_{1,2}$ را پس از بلاتری دارند رای کامیابی، بنابراین در آن آرم بهینه، باید تعداد نیزه بیشتری از آن در آرم جمع کنیم.



SADEGHI

② آنالیزی Δ ، Δ بزرگتر به این معنی است که آرم بهینه به صورت سختی از آرم
 بهینه بهتر است بنابراین به تری شدن از یکدیگر در سختی کردن آرم بهتر است
 چون توزیع آن‌ها بسیار شباهت است در نتیجه در exploration بهتری می‌خواهیم.

How to model with Bandits ②

1) در Stochastic model هر آرم a یک توزیع پیرا P_a با میانگین μ_a
 دارد. regret ، پاسی را با آرم a را می‌بینیم به سبب μ_a ، به صورت سختی
 play به نوبت می‌کند

$$R_n(\pi, \nu) = n\mu^*(\nu) - \mathbb{E} \left[\sum_{t=1}^n K_t \right]$$

در adversarial model ، پیرایه $\mu_{t,a}$ می‌تواند به صورت دلخواه از زمان

تغییر کند در نتیجه بازی سخت آرم‌ها توزیع می‌کند stationary یا میانگین ثابت

راسته باشد در نتیجه سارنای به این مدل بهترین arm ثابت $\max_{a \in A} \sum_{t=1}^n \mu_{t,a}$

است به این adversarial regret ، difference میان cumulative reward
 برای بهترین آرم ثابت ، expected cum reward برای learner است

که این ریاضی روی رندومیزیشن learner است

تقریب stochastic ثابت است چون نادیده P_a, μ_a, μ^*

چون است در adversarial setting باشد ، جمع expected stationary
 ای برای جمع آرم وجود ندارد که به عنوان benchmark استفاده reward



SADEGHI

۱۲ adversary ، دنبای از ریدر انتاب می کند و Policy می آن
ارزایی می شود . Regret نشان می دهد که پالیسی در مقابل بهترین آرم چقدر

با بهترین گزینه کمتر ریدر از دست داده

اگر در هر دور همه آرم ها ریدر یکسانی دریافت کنند پالیسی نسبت به اینکه هر آرم چقدر

ریدر به دست می آید در نتیجه $R_n(K, K)$ بین بدترین و بهترین ریدر ها صفر است

نسبت به هر یک از ریدر ها باید باشد.

۱۳ نه صورت سیستم و ETC ، UCB نیاز به stationary stochastic reward

دارند و می توانند هر ششای ریدر ها شوند.

یک پالیسی deterministic تابع ششای است. با داشتن اینکه کدام آرم را در round +

انتاب می کند یک adaptive adversary می تواند به آن آرم یک ریدر پائین اضافه

بدید و به یک آرم دیگر ریدر زیاد که بهر به regret خطی می شود اگر سیستم های

adversarial bundit در نتیجه از randomization استفاده می کنند EXP3

۱۴ یک استرژیک بودن؟ sublinear regret می رسد که $R_n = o(n)$ در نتیجه پائین regret

$R_n / n \rightarrow 0$ ، خطی ، همگرا ، تقریباً ، عملکرد بهترین آرم چقدر

این اتفاق به واسطه randomization ، exploration ، از ریدر انسان نتیجه است و ششای
Learner نیز تابع ششای می باشد از arm های مختلف نمونه می گیرد ، از ریدر ها که



استاره می‌کنند تا همکاران آن‌ها را متوجه نهند، از exploit کردن ستر انتخاب می‌کنند

در سطح adversarial طراحی کنند یک کاربرد خود online advertising است که برادر کلیک‌ها بخاطر trend ممکن است تغییر کند، اینجا مدل‌لیسا غیر منطقی است.

(5) adversarial bandit می‌گویند توزیع‌های تغییر می‌دهد، اما مدل‌کننده چون

stationary assumption ای لحاظ نمی‌کنند با این حال خوب بودن آن‌ها، بسته به benchmark است.

adversarial regret استاندارد learner را با بهترین آرم ثابت با نگاه به گذشته مقایسه می‌کنند

این زمانی مناسب است که محدث با سابقه دادن باید آرم‌هاست که در horizon استفاده می‌کند

مقایسه آن reward عادی در طول زمان می‌کند.

در صورتی که identity بهترین آرم تغییر کند، benchmark ممکن است بی‌ارزش باشد

به learner می‌گویند regret کمی‌بسته باشد در مقایسه با best fixed arm

در حالتی که نتواند arm‌ای که در هر لحظه بهترین است را دنبال کند.

در این حالت استفاده از یک مدل non-stationary یا dynamic regret

که عملکرد learner را با بهترین آرم در هر لحظه مقایسه می‌کنند یا regret

تغییر arm که مقدار محدودی تغییر را برای arm سایر مجاز است مناسب‌تر است.

(6) Linear/OFUL استفاده از یک مجموعه action، شیرازمان را زاعم می‌کنند

در هر + پس از مشاهده c_t

$$X_t \in \{ \psi(c_t, a) : a \in A \}$$

$$a_t \leftarrow \arg \max_{a \in A} \left[\underbrace{\langle \hat{A}_t, \psi(c_t, a) \rangle}_{\text{exploration}} + \underbrace{\beta_t \|\psi(c_t, a)\|}_{\text{exploitation}} \right]$$

تغییر برای exploration

در context-action

غیر منطقی



SADEGHI

Confidence set برای θ^* است. از تمام بردارهای رتبه‌ی که در درجه‌ی سالی استفاده می‌شود. در نتیجه optimism را می‌توانیم به هم می‌زنیم. جاری
اعمال کرد. Context نیکی را اعلام می‌کند. بنابراین تمام استاندارد می‌تواند Context
بسیار با Context های که صورت adversarial انتی - بدهاند را
گردد. به شرطی که linear reward، رتبه‌ی سالی مربوط به نیز رفتار باشد

regret نسبت به oracle، بسته به Context از برای می‌شود

$$a_t \in \arg \max_{a \in A} \langle \theta^*, \psi(t, a) \rangle$$

در نتیجه، تیم لازم این است که $\lim_{t \rightarrow \infty} \text{UCB score}$ را در action های مورد
Context سالی و به هم می‌زنیم.

Reduction (۳)

(۱) برای آشنی e_i بردار رتبه - صورت $r_t = \langle \theta^*, e_t \rangle + \eta_t = \theta_i^* + \eta_t$
است. نتیجه گرفته θ^* (تقریباً) بیابان بردارهای یک آرم است. در نتیجه این bandit
فقط به یک d-armed bandit مدل تبدیل می‌شود.

$$Q_{in \text{ UCB}} = V_t = \lambda I + \sum_{s \in S} \lambda_s n_s = \text{diag}(\lambda + n_1(t), \dots, \lambda + n_d(t))$$

$$\|e_i\|_{V_t^{-1}} = \frac{1}{\sqrt{\lambda + n_i(t)}} \quad n_i(t) \text{ تعداد بولد های آرم } i \text{ است در نتیجه}$$

$$\hat{\theta}_{t+1} = \beta_t + \frac{1}{\sqrt{\lambda + n_i(t)}} \quad \text{in UCB} \text{ اندکس هم}$$

$$\hat{\mu}_{i,t+1} = \frac{\sum_{s \in S} \lambda_s \log(t)}{n_i(t)} \quad \text{idx به بالا}$$

Confidence width

$$\text{radius } \alpha = \frac{1}{\sqrt{n_i(t)}}$$

SADECHI



از آنجایی که action $\int \text{orthogonal}$ سلسله کوکون یک آرم اطلاعاتی

راه، arm دیگر نمی رسد در نتیجه generalization اضافه تر فراهم می کند

تفاوت، ثابت regularization constant in VCB از $\text{nil}()$

β_t استوار می کند، VCB از bound $(\text{Dist}/\text{nil}())$ است

می کند در نتیجه in VCB رتبه، سلسله با VCB بدون دارد

(ϵ) محترم ϵ در $\hat{\Delta}_t$ ridge estimate یک $\text{ellipsoid centered}$ است

آنها λ_t $\text{diag}(\lambda_1, \dots, \lambda_d)$ ، $\text{Vol}(\epsilon_t) = \text{Vol}(\Delta_t)$

محورها اساس آن بردار ویژه ϵ_t ، Vol semi-axis

در جهت λ_t $\left(\frac{\beta_t}{\lambda_t}\right)$ است در نتیجه جهت ما با سلسله های informative مقابله می کند

بزرگ دارد، uncertainty آن کم است در Volume آن $\frac{\text{Vol}(\epsilon_t)}{\text{Vol}(\beta_t)}$ $\frac{dK}{\det(V_{t-1})}$

d -dimensional
unit ball

است از آنجایی که $\epsilon_t = \epsilon_{t-1} + \eta_t \lambda_t$ است

$\text{information matrix}$ در طول زمان بزرگ می شود در نتیجه سلسله های ویژه در درجهان بزرگتر می شود

در نتیجه حدا از بزرگ شدن β_t ، ellipsoid volume کاهش می یابد

سلسله های uncertainty را کم کردن مفید در حتماً به صورت یک

از آنجا که سلسله بزرگتر است



SADECHI

$$T = \inf\{t \geq 1 : A_t = 2\}$$

10

$$\textcircled{1} \mu_1, \mu_2$$

arm optimal است و $T < \infty$ policy

suboptimal برای T بزرگ تر از T بازی می کند

$$R_n(\pi, \mu_1) = (\mu_2 - \mu_1) \mathbb{E}_{\mu_1}[(n - T + 1) \mathbb{1}_{\{T \leq n\}}]$$

dominated

Convergence

$$\lim_{n \rightarrow \infty} \frac{R_n(\pi, \mu_1)}{n} = (\mu_2 - \mu_1) \Pr(T < \infty)$$

$$\textcircled{2} \mu_1 < \mu_2$$

arm 2 optimal است تدار (pull) arm 1 که نیمی است

برای $t \leq \min\{n, T-1\}$ است

$$R_n(\pi, \mu_1) = (\mu_2 - \mu_1) \mathbb{E}_{\mu_1}[\min\{n, T-1\}]$$

$$\Rightarrow \lim_{n \rightarrow \infty} \frac{R_n(\pi, \mu_1)}{n} = (\mu_2 - \mu_1) \Pr(T < \infty)$$

Policy π با احتمال π برای T بزرگ تر از T بازی می کند

$$\Pr(T=t) > 0 \quad \leftarrow \quad \Pr(T < \infty) > 0$$

finite Bernoulli history نه $(1, 0)$ بازی می کند

$$\Pr(T=t) > 0 \quad \leftarrow \quad \Pr(T < \infty) > 0$$

$$\lim_{n \rightarrow \infty} \frac{R_n(\pi, \mu_1)}{n} > 0$$

اگر $\mu_1 < \mu_2$ و $\Pr(T < \infty) > 0$ برای μ_1 و μ_2 با احتمال μ_1 بازی می کند

$$\lim_{n \rightarrow \infty} \frac{R_n(\pi, \mu_1)}{n} = \mu_2 - \mu_1 > 0$$



retirement Policy نه T بزرگ تر از T بازی می کند

$$\lim_{n \rightarrow \infty} \sup \frac{R_n(\pi, \mu_1)}{n} > 0$$

log

Mirror Decent and FTRL (2)

a) $f(n) = n^2$ on $[-1, 1]$: Not Legendre (1)

$n = \pm 1$, $f(n) = n^2$ is differentiable, strictly convex

is finite

b) $f(n) = -\sqrt{n}$ on $[0, \infty)$: Legendre

$n \geq 0$

$$f''(n) = \frac{1}{4n^{3/2}} > 0 \quad f'(n) = -\frac{1}{2\sqrt{n}} \rightarrow -\infty$$

as $n \rightarrow 0^+$

c) $f(n) = \log(1/n) = -\log n$: Legendre

$n > 0$

$$f''(n) = \frac{1}{n^2} > 0, \quad f'(n) = -\frac{1}{n} \rightarrow -\infty$$

as $n \rightarrow 0^+$

d) $f(n) = n \log n$, $f(0) = 0$: Legendre

$n > 0$

$$f''(n) = \frac{1}{n} > 0, \quad f'(n) = 1 + \log n \rightarrow -\infty$$

as $n \rightarrow 0^+$

e) $f(n) = |n|$ on $\mathbb{R}$: Not Legendre

is not strictly convex, $f'(n)$ does not exist at $n=0$

1)

SADEGHI



f) $f(x) = \max\{|x|, x^2\}$ on $\mathbb{R}$, Not Legendre

برای $|x|$ و x^2 در تمام $\mathbb{R}$ مشتق پذیر و صاف است،
strictly convex است.

$$S_{t-1}, \sum_{s=1}^{t-1} y_s$$

(۲)

$$a_{t+1} = \arg \min_{a \in [-1, 1]} \begin{cases} -1 & S_{t-1} > 0 \\ +1 & S_{t-1} < 0 \end{cases} \quad \text{یعنی } a_t \text{ FTL}$$

برای این دلیلی

$$S_{n-1} = \begin{cases} \frac{1}{2} & n \text{ زوج} \\ -\frac{1}{2} & n \text{ فرد} \end{cases}$$

$$\Rightarrow a_{t+1} = \begin{cases} -1 & \text{زوج} \\ +1 & \text{فرد} \end{cases}$$

$$y_t = \begin{cases} -1 & \text{زوج} \\ +1 & \text{فرد} \end{cases}$$

$$\Rightarrow a_{t+1} = 1 \quad (t \text{ زوج})$$

$$\Rightarrow L_T^{\text{FTL}} = a_1 y_1 + (T-1) \cdot \frac{1}{2} + T - 1$$

$$\rightarrow \min_{a \in [-1, 1]} a \left(\sum_{t=1}^T y_t - \left| \sum_{t=1}^T y_t \right| \right) \left| a - \frac{1}{2} \right|$$

$$\Rightarrow R_T = T - \frac{1}{2} + \frac{1}{2} \cdot T - 1 \rightarrow \text{در } T \text{ ضعیف است}$$

این کمترین اشتباه می‌باشد چون FTL رعایت Cumulative Loss پای را دنبال می‌کند از آن جایی که این رعایت در هر دو تغییر می‌کند



این الگوریتم به صورت تکراری action ما را تعیین می‌کند، تصمیم action ای که انتخاب می‌کند که برای loss بعدی برآید.

SADECHI

$$S_{t-1}, \sum_{s=1}^{t-1} y_s$$

(۲)

FTRL update: $a_t = \arg \min_{a \in [-1, 1]} \{ \eta a S_{t-1} + a^2 \}$

$$\Rightarrow \eta S_{t-1} + 2a = 0 \rightarrow a_t = \frac{\Pi_{[-1, 1]} \left(-\frac{\eta}{2} S_{t-1} \right)}{\Pi_{[-1, 1]}}$$

$\Pi_{[-1, 1]} \rightarrow$ Projection onto $[-1, 1]$

برای ساده‌سازی

$$S_{t-1} \cdot \begin{cases} \frac{1}{\eta} & \text{if } z_t \geq 0 \\ -\frac{1}{\eta} & \text{if } z_t < 0 \end{cases}$$

$$\Rightarrow a_{t=0}, a_t = \begin{cases} -\min \{ \eta/4, 1 \} & \text{if } z_t \geq 0 \\ \min \{ \eta/4, 1 \} & \text{if } z_t < 0 \end{cases}$$

برای FTL برای η بین -1 و 1 quadratic regularization

action با نزدیک‌تر به صفر باشد. برای $\eta/4$ action به اندازه $\eta/4$ دارد

در این سیستم که به تدریج cumulative loss به تدریج است، per-round loss می‌باشد

Bregman divergence $D_F(a, b) = F(a) - F(b) - F'(b)(a - b) = (a - b)^2$ (۳)

mirror descent $a_{t+1} = \arg \min_{a \in [-1, 1]} \{ \eta a y_t + (a - a_t)^2 \}$

$$\Rightarrow a_{t+1} = \Pi_{[-1, 1]} \left(a_t - \frac{\eta}{2} y_t \right) \quad a_{t=0}$$

FTRL $a_{t+1} = \Pi_{[-1, 1]} \left(-\frac{\eta}{2} \sum_{s=1}^t y_s \right)$

SADEGHI



زبان Project زبان است mirror Descent recursion استوری می کرد

$$\rightarrow x_{t+1} = x_t - \eta \sum_{s=1}^t y_s$$

update با یکبار کنند

رای این زبان تغییر خاص با هم صاف می کنند clipping استای می کنند

$$a_{t+1} = \begin{cases} -\min\{\eta y_t, 1\} & \text{از } t \\ \min\{\eta y_t, 1\} & \text{از } t+1 \end{cases}$$

FTRL, Mirror Descent, iterate با استای با در این است

بصورت کلی می توان است زبانی به boundary می کنند با هم نزدیکتر می

mirror Descent از project action می update می کنند

FTRL با استفاده از cumulative loss می کنند

$$\text{FTRL} \quad \min_{P \in \mathcal{P}_{t-1}} \left\{ \eta \sum_{i=1}^k P_i L_{t-1,i} - \sqrt{\sum_{i=1}^k P_i} \right\} \quad (10)$$

از آن بای ستن $\sqrt{P_i}$ زبانی $\rho \rightarrow 0^+$: $\rho - \infty$ می

minimizer interior است $P_{t,i} > 0$

$$\lambda_{t+1} = \frac{1}{\sum_{i=1}^k P_{t,i}} \left(\lambda_t + \eta L_{t-1,i} \right)$$



SADECHI

$$\Rightarrow P_{t,i} = (\lambda_t + \eta L_{t-1,i})^{-\alpha}$$

$$\sum_{i=1}^K (\lambda_t + \eta L_{t-1,i})^{-\alpha}$$

$$h(\lambda) = \sum_{i=1}^K (\lambda + \eta L_{t-1,i})^{-\alpha} \quad \lambda \geq -\eta \min_i L_{t-1,i}$$

$h \rightarrow$ بیست، آسا نزی

$h(\lambda) \rightarrow \infty$ در boundary $h(\lambda) = 0 \leftarrow \lambda \rightarrow \infty$ رت

λ یک مقدار دارد که $h(\lambda_t) = 1$ باشد

$i \neq 0$

$$L_{t,i}, L_{t-1,i} + \hat{Y}_{t,i} \quad \hat{Y}_{t,i} = \frac{y_{t,i}}{P_{t,i}}$$

$i \neq 0$ (حالی که $L_{t,i} = L_{t-1,i}$)

در اینجا از $P_{t,i}$

$$\Rightarrow P_{t,i} = (\lambda_t + \eta L_{t-1,i})^{-\alpha}$$

$$P_{t+1,i} = (\lambda_{t+1} + \eta L_{t,i} + \eta \hat{Y}_{t,i})^{-\alpha}$$

$$P_{t+1,i} < P_{t,i}$$

در حالت اول

$$\lambda_{t+1} + \eta L_{t,i} + \eta \hat{Y}_{t,i} < \lambda_t + \eta L_{t-1,i}$$

$$\Rightarrow \lambda_{t+1} < \lambda_t - \eta \hat{Y}_{t,i}$$

$\forall i \neq 0 \rightarrow$ بررسی کنید

$$\Rightarrow P_{t+1,i} = (\lambda_{t+1} + \eta L_{t,i} + \eta \hat{Y}_{t,i})^{-\alpha} > (\lambda_t + \eta L_{t-1,i})^{-\alpha} = P_{t,i}$$

از آنجایی که احتمالات اثرات مثبت دارند

SADEGHI



$$P_{t+1}, A_t \leftarrow P_t, A_t \quad \leftarrow \quad \boxed{\sum_i P_{t+1,i} \sum_i P_{t,i}}$$

نصرت سردی، جاسریک و دیو ا سنی arm انتاب نه لیه خراب می کند
 ← FTRL خیرانه میرا اصلان ستر به آن برسد.

$$F(P), -2 \sum_{i=1}^K \sqrt{P_i} \rightarrow \frac{\partial F}{\partial P_i} = -\frac{1}{\sqrt{P_i}} \quad (17)$$

$$\rightarrow \frac{\partial^2 F}{\partial^2 P_i} = \frac{1}{2 P_i^{3/2}}$$

$$i \neq j, \quad \frac{\partial^2 F}{\partial P_i \partial P_j} = 0$$

$$\Rightarrow \nabla^2 F(P), \frac{1}{2} \text{diag}(P_1^{-\frac{3}{2}}, \dots, P_K^{-\frac{3}{2}}) = \frac{1}{2} \text{diag}(P^{-\frac{3}{2}})$$

آن جی نه دران از diagonal است است F آلیا convex است
 (interior simplex)

$$*P_i \rightarrow 0^+ \quad \frac{1}{2 P_i^{3/2}} \rightarrow \infty$$

boundary, regularizer, curvature, بزرگی نزدیک

دارد که در سایه تنهایی نه اصالت به سمت صفری بریزد، ثابت می کند

$$\forall P \in P_{K-1}$$

$$1 \leq \sum_{i=1}^K \sqrt{P_i} \leq \sqrt{K}$$

$$\text{lower bound} \rightarrow \sum_{i=1}^K \sqrt{P_i} \geq \sum_{i=1}^K P_{i,1}$$

$$\text{upper bound} \rightarrow \sum_{i=1}^K \sqrt{P_i} \leq \sqrt{K} \sum_{i=1}^K P_i \leq \sqrt{K}$$

$$\Rightarrow -\sqrt{K} \leq F(P) \leq -2 \sum_{i=1}^K \sqrt{P_i} \leq -2$$

$$\Rightarrow \text{diam } F(P_{K-1}) = \sup_{P, Q} |F(P) - F(Q)| \leq 2(K-1) \leq 2\sqrt{K}$$

$$\Rightarrow \text{diam}(P_{K-1}) \leq 2\sqrt{K}$$



SADEGHI

begin

Notebook

Year /

Month /

Date /

$$\forall u \in P_{k-1} \quad \sum_{t=1}^n \langle P_t - u, \hat{Y}_t \rangle \leq \frac{\text{diam}_F(P_{k-1})}{\eta} + \frac{1}{\eta} \sum_{t=1}^n \hat{Y}_t^T (\nabla^2 F(P_t))^{-1} \hat{Y}_t \quad (4)$$

از $\nabla^2 F$ داریم $\rightarrow \text{diam}_F(P_{k-1}) \leq \sqrt{k}, (\nabla^2 F(P_t))^{-1} = \frac{1}{\eta} \text{diag}(P_t^{-1})$

از $\hat{Y}_t$ داریم $\hat{Y}_t^T (\nabla^2 F(P_t))^{-1} \hat{Y}_t = \frac{1}{\eta} \sum_{i=1}^k \frac{(y_{t,i} A_{t,i})^2}{P_{t,i} A_{t,i}} = \frac{y_{t,i}^2 A_{t,i}}{P_{t,i} A_{t,i}}$

$$\Rightarrow \mathbb{E}_t \left[\frac{y_{t,i}^2 A_{t,i}}{P_{t,i} A_{t,i}} \right] \leq \frac{1}{\eta} \sum_{i=1}^k \sqrt{P_{t,i}} y_{t,i} \leq \frac{1}{\eta} \sum_{i=1}^k \sqrt{P_{t,i}} \leq \sqrt{k}$$

این یک importance weighted estimator است

از L داریم $R_n \leq \frac{\sqrt{k}}{\eta} + \eta \sqrt{k} \quad z_i \in \mathbb{R}^n, u \in \mathbb{R}^n$

از $\frac{1}{\sqrt{n}}$ داریم $\rightarrow R_n \leq \sqrt{k} + \sqrt{k} \eta \sqrt{n} \quad O(\sqrt{k}n)$ regret

در k بازخورد bandit feedback، R regret است.

10) Mirror Descent (بازخورد) Bregman Divergence f

$$P_{t+1} = \arg \min_{P \in P_{k+1}} \{ \eta \langle P, \hat{Y}_t \rangle + D_f(P, P_t) \}$$

$$\nabla f(P) = -P^{-1} \eta \rightarrow P_{t+1,i} = (P_{t,i}^{-1} + \eta \hat{Y}_{t,i} + \eta_t)^{-1}$$

از $P_{t+1,i}$ داریم $\frac{1}{P_{t+1,i}} = \frac{1}{P_{t,i}} + \eta \hat{Y}_{t,i} + \eta_t$

recursion $P_1 = (\frac{1}{k}, \dots, \frac{1}{k}) \rightarrow P_{t,i}^{-1} = \frac{1}{k} + \eta \sum_{s=1}^{t-1} \hat{Y}_{s,i}$

$$\rightarrow P_{t,i} = \left(\frac{1}{k} + \eta \sum_{s=1}^{t-1} \hat{Y}_{s,i} \right)^{-1}$$

SADEGHI



آدمی و آبی FTRL است روشی برای تنظیمات Mirror Descent

learning rate ، تنظیمهای بسیاری را بررسی کند با فرض اینکه از

initialization بسیاری استادی کنند

← Mirror Descent ، انتخابی بسیاری برای reset دارد

$$\eta = \sqrt{\frac{2}{n}} \rightarrow R_n \leq \sqrt{Kn}$$

(1)

$L_{0,i} = 0 \quad \forall \text{ arm}$

در هر دور t

1) compute L_t , satisfying

$$g(\lambda_t) = \sum_{i=1}^K (\lambda_t, \eta L_{t-1,i})^{-2}$$

$g \rightarrow$ continuous, strictly decreasing

use bisection on $-\eta_{\min} L_{t-1,i} < \lambda_t < \sqrt{K} - \eta_{\min} L_{t-1,i}$

$$\forall \text{ set } p_{t,i} = (\lambda_t + \eta L_{t-1,i})^{-2}$$

2) sample A_t from categorical dist' p_t , observe y_{t,A_t}

$$3) \text{ construct } \hat{Y}_{t,i} = \begin{cases} \frac{y_{t,A_t}}{p_{t,A_t}} & i = A_t \\ 0 & i \neq A_t \end{cases}$$

4) update $L_{t,i} = L_{t-1,i} + \hat{Y}_{t,i}$

در هر دور t cumulative loss را میابیم و آن را در η ضرب می‌کنیم

$$O(K \log(\frac{1}{\epsilon}))$$

Bisection λ_t در دسترس ϵ_t در

در دسترس



SADECHI